

Teknik Rapor

İzmir / Buca Kiralık Konut Fiyat Tahmini
Linear Regression ve XGBoost Karşılaştırması

1. Amaç

Bu çalışmanın amacı, **Hepsiemlak** platformundan alınan kiralık konut ilanlarını kullanarak aylık kira bedelini tahmin eden regresyon modelleri geliştirmek ve iki yöntemi — **Linear Regression** ve **XGBoost Regressor** — aynı veri, aynı özellikler ve aynı değerlendirme yöntemiyle karşılaştırmaktır. Çalışma; veri temizleme, keşifsel analiz, modelleme ve performans değerlendirmesi adımlarını içerir.

2. Veri Seti

Veri, Hepsiemlak'ta yayınlanan **687 kiralık ilandan** oluşan bir CSV dosyasıdır (*hepsiemlak.csv*). İlanların tamamı **İzmir'in Buca ilçesine** aittir; yayın tarihleri 14 Temmuz – 11 Ekim 2024 arasındadır (ilanların büyük çoğunluğu Eylül-Ekim 2024). Veri Python (pandas, scikit-learn, XGBoost) ile işlenmiş, çalışma Google Colab veya yerel Jupyter ortamında çalıştırılabilecek biçimde hazırlanmıştır.

Ham veride her ilan için ilan tarihi, kategori, ilan başlığı, konum (il / ilçe / mahalle), kat, bina yaşı, oda sayısı, brüt metrekare ve fiyat bilgisi bulunur. Modelde kullanılan değişkenler aşağıdadır:

Değişken	Ham biçim (örnek)	Modeldeki karşılığı
Mahalle	İzmir / Buca / Atatürk Mah.	Kategorik — one-hot (41 mahalle; 5'ten az ilanı olanlar tek grupta)
Oda sayısı	3 + 1, Stüdyo	Sayısal — <i>rooms</i> (oda) ve <i>salon</i> ayrı
Brüt metrekare	130 m ²	Sayısal — <i>gross</i>
Bina yaşı	25 Yaşında, Sıfır Bina	Sayısal — <i>age</i> (Sıfır Bina = 0)
Bulunduğu kat	2. Kat, Ara Kat, Yüksek Giriş	Sayısal kat no + kat tipi (Bodrum / Giriş / Numaralı / Ara / Üst)
Fiyat (hedef)	20.000	Sayısal — aylık kira (TL)


Not: Veri setinde şehir, ısıtma türü gibi değişkenler **yoktur**; sonuçlar yalnızca Buca ilçesi için geçerlidir.

3. Veri Ön İşleme

Ham verideki tüm sütunlar metin biçimindedir; sayısal değere çevrilmiştir (ör. "25 Yaşında" → 25, "130 m²" → 130, "20.000" → 20000). Temizleme sırasında şu kararlar alınmıştır:

- Aykırı fiyatlar çıkarıldı (13 ilan).** 11 ilan günlük kiralıktır (200–400 TL/gün), 1 ilan satılık daire (2.750.000 TL), 1 ilan ise günlük kiralık olup 300.000 TL girilmiştir. Bunlar aylık kira değildir ve hata ölçütlerini ciddi biçimde bozar. Kural olarak fiyatı 3.000–100.000 TL dışında kalan ilanlar çıkarılmıştır.
- Tekrar eden 2 ilan silinmiştir.** Sonuçta **672 ilan** kalmıştır (medyan kira 18.000 TL, ortalama 18.931 TL).
- Oda sayısı** "oda + salon" olarak ayrıştırılmış; "11 + 18" ve "3 + 11" gibi girdi hataları eksik değer sayılmıştır (2 ilan).


- **Kat bilgisi** "Ara Kat" ve "En Üst Kat" gibi sayıya çevrilemeyen değerler içerir (112 ilan); bu ilanlarda sayısal kat medyan ile doldurulmuş, kat tipi ayrı bir kategorik değişken olarak modele verilmiştir.
- **Kodlama:** Mahalle ve kat tipi için *LabelEncoder* yerine **one-hot** kodlama kullanılmıştır. *LabelEncoder* kategorilere alfabetik sıraya göre 0, 1, 2... atadığı için doğrusal modelde anlamsız bir sıralama ilişkisi yaratır.



Şekil 1. Fiyat dağılımı: ham veri (solda) ve aykırı ilanlar çıkarıldıktan sonra (sağda).

4. Keşifsel Analiz

Fiyatla en güçlü ilişki **brüt metrekare** ($r = 0,65$) ve **oda sayısı** ($r = 0,61$) ile görülür; alan ve oda sayısı arttıkça kira artmaktadır. Kat numarasıyla ilişki orta-zayıf ($r = 0,31$), bina yaşı ve salon sayısı ile ilişki çok zayıftır ($r \approx 0,06-0,08$). Kat tipine bakıldığında giriş (medyan 15.000 TL) ve bodrum (15.000 TL) katları, numaralı, ara ve üst katlara (medyan ≈ 18.500 TL) göre daha ucuzdur. Mahalleler arasında da fark vardır: en çok ilanı olan mahallelerde medyan kira Kuruçeşme'de 16.000 TL, Hürriyet'te 20.000 TL, İnkılap'ta 21.000 TL'dir.



Şekil 2. Kira ile metrekare, oda sayısı, bina yaşı ve kat tipi arasındaki ilişkiler.

5. Modelleme

İki model de **aynı özellikler, aynı ön işleme ve aynı eğitim/test bölünmesi** ile eğitilmiştir. Veri %80 eğitim (537 ilan) ve %20 test (135 ilan) olarak ayrılmıştır (*random_state* = 42). Test seti eğitim ve hiperparametre seçimi sırasında hiç kullanılmamıştır.

- **Linear Regression:** basit, hızlı ve yorumlanabilir temel model.
- **XGBoost Regressor:** ağaç tabanlı, doğrusal olmayan ilişkileri yakalayabilen model. Hiperparametreler yalnızca eğitim seti üzerinde 5-katlı çapraz doğrulamalı GridSearchCV ile seçilmiştir (*n_estimators*, *max_depth*, *learning_rate*, *subsample*). Seçilen değerler: 200 ağaç, *max_depth* = 3, *learning_rate* = 0,03, *subsample* = 0,8.

Veri yalnızca yaklaşık 670 ilandan oluştuğu için, tek bir test bölünmesine ek olarak **tüm veri üzerinde 5-katlı çapraz doğrulama** da uygulanmıştır; bu değerler tek bir bölünmenin şansına daha az bağlıdır.

6. Performans Karşılaştırması

Test seti (%20, 135 ilan):


Model	RMSE (TL)	MAE (TL)	MAPE	R ²
Linear Regression	3.394	2.494	%13,0	0,649
XGBoost	3.397	2.351	%12,3	0,648

5-katlı çapraz doğrulama (tüm veri, 672 ilan):

Model	RMSE (TL)	MAE (TL)	MAPE	R ²
Linear Regression	3.761 (± 263)	2.714	%14,9	0,536
XGBoost	3.732 (± 274)	2.649	%14,4	0,539

İki modelin hata değerleri birbirine çok yakındır. Çapraz doğrulamada RMSE farkı yalnızca **29 TL**'dir ve katlar arası standart sapmanın ($\approx$ 270 TL) çok altında kalır; bu nedenle **iki model pratikte eşdeğerdir**. XGBoost MAE ve MAPE'de küçük bir avantaj gösterse de bu fark, mevcut veriyle istatistiksel olarak anlamlı sayılamaz. Test setindeki R² (0,65), çapraz doğrulamadakinden (0,54) yüksektir; bu, tek bir test bölünmesinin biraz iyimser olabildiğini gösterir ve çapraz doğrulama değerleri esas alınmalıdır.

Ortalama olarak her iki model de tahminlerde yaklaşık 2.400–2.700 TL (çapraz doğrulamada $\approx$ %14–15) sapmaktadır. Örnek: Atatürk Mahallesi'nde, 100 m², 3+1, 5 yaşında, 3. kattaki bir daire için tahmini kira Linear Regression ile 22.832 TL, XGBoost ile 21.979 TL'dir.



Şekil 3. Test setinde gerek ve tahmin edilen kira deęerleri (kesikli izgi mükemmel tahmindir). Yüksek kiralı (35.000 TL üzeri) ilanlarda iki model de kirayı düşük tahmin etmektedir.

Deęişkenlerin etkisi

Linear Regression katsayılarına göre, dięer deęişkenler sabitken: her ek oda yaklaşık **+1.807 TL**, her ek salon **+731 TL**, her ek metrekare **+75 TL**, her üst kat **+210 TL**, bina yaşındaki her ek yıl ise yaklaşık **-246 TL** kira farkı yaratmaktadır. XGBoost'ta en yüksek önem oda sayınsındadır; onu brüt metrekare ve mahalle bilgisi izler. Az ilanı olan bazı mahallelerin önem deęerinin yüksek ıkması (ör. yalnızca 5 ilanı olan Aydoędu) küçük örneklemden kaynaklanabilir ve dikkatle yorumlanmalıdır.

7. Sonuç ve Sınırlılıklar

Bu alıřmada Hepsiemlak verisiyle İzmir/Buca iin kira tahmin modeli geliřtirilmiřtir. Aykırı ilanların (günlük kiralık ve satılık) temizlenmesi ve kategorik deęişkenlerin doęru kodlanması, sonuçların güvenilirlięi aısından belirleyici olmuřtur. Modeller ortalama olarak yaklaşık %14-15 hata ile tahmin yapmakta, kira farklarının yaklaşık yarısını ($R^2 \approx 0,54$) aıklayabilmektedir. **Bu veri setinde XGBoost, Linear Regression'a göre belirgin bir üstünlük saęlamamıřtır**; bu nedenle daha basit ve yorumlanabilir olan Linear Regression makul bir tercih olarak öne ıkmaktadır.

- Veri tek bir ilçeyi (Buca) ve yaklaşık üç aylık bir dönemi kapsar; sonuçlar başka ile, řehir veya dönemlere genellenemez. Enflasyonun yüksek olduęu bir dönemde tarih etkisi de fiyatlara yansımıř olabilir.
- İlan fiyatları gerekleşen kira bedelini deęil, ilan sahibinin istedięi bedeli gösterir.
- Eřyalı/eřyasız, site ii, ısıtma türü, balkon/otopark gibi fiyatı etkileyen deęişkenler veri setinde bulunmamaktadır; ilan bařlıęından metin madencilięi ile ıkarılması ve daha fazla ilan toplanması modeli iyileřtirebilir.
- Yüksek kiralı ilanlarda tahminler sistematik olarak düşüktür; bu aralıkta daha fazla örnek gerekir.